

# MULTI-LABEL CLASSIFICATION OF THORAX DISEASES ON CHEST X-RAY

Saul Gomez, Mateo Rueda, Diego Valderrama

Mayo 2019

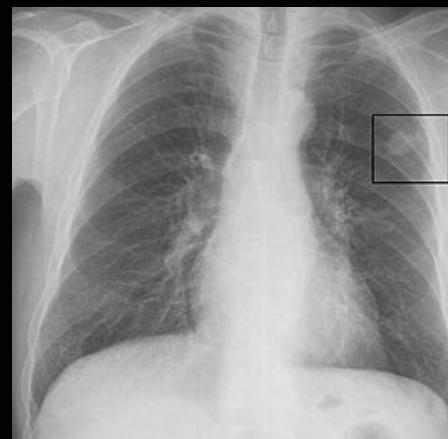
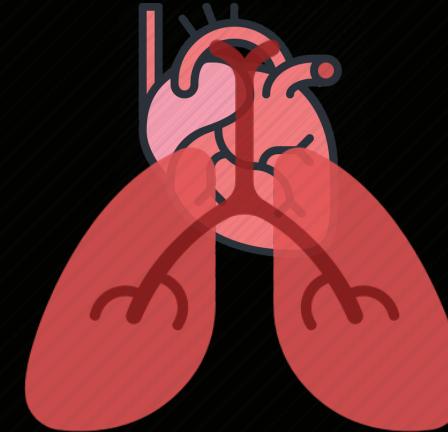
# ENFERMEDADES DE THORAX

GRAN VARIEDAD DE ENFERMEDADES

DIAGNÓSTICO MEDIANTE ANÁLISIS DE IMÁGENES MÉDICAS (CT O RAYOS X)

TAREA DIFÍCIL INCLUSO PARA RADIÓLOGOS EXPERIMENTADOS

# Dificultades



ESTRUCTURAS  
ANATÓMICAS  
SOBRELAPADAS

RASGOS PEQUEÑOS Y  
SUTILES



CORRELACIÓN CON  
HISTORIA CLÍNICA

# APROXIMACIONES EN VISIÓN POR COMPUTADOR

- ▶ Ecuación de histogramas
- ▶ Detección automática de enfermedades de thórax individualmente
- ▶ Redes Neuronales Convolucionales

# BASE DE DATOS

- ▶ 112119 imágenes de rayos X de pecho
  - ▶ 78484 imágenes de entrenamiento
  - ▶ 8039 imágenes de validación
  - ▶ 25596 imágenes de test
  - ▶ Los labels son las enfermedades del paciente
  - ▶ Curvas Roc y auroc score por enfermedad
- 



# ENFERMEDADES A CLASIFICAR



ATELECTASIS

CARDIOMEGALIA

EFUSIÓN

INFILTRACIÓN

MASA

NÓDULO

PNEUMONIA

PNEUMOTÓRAX

CONSOLIDACIÓN

EDEMA

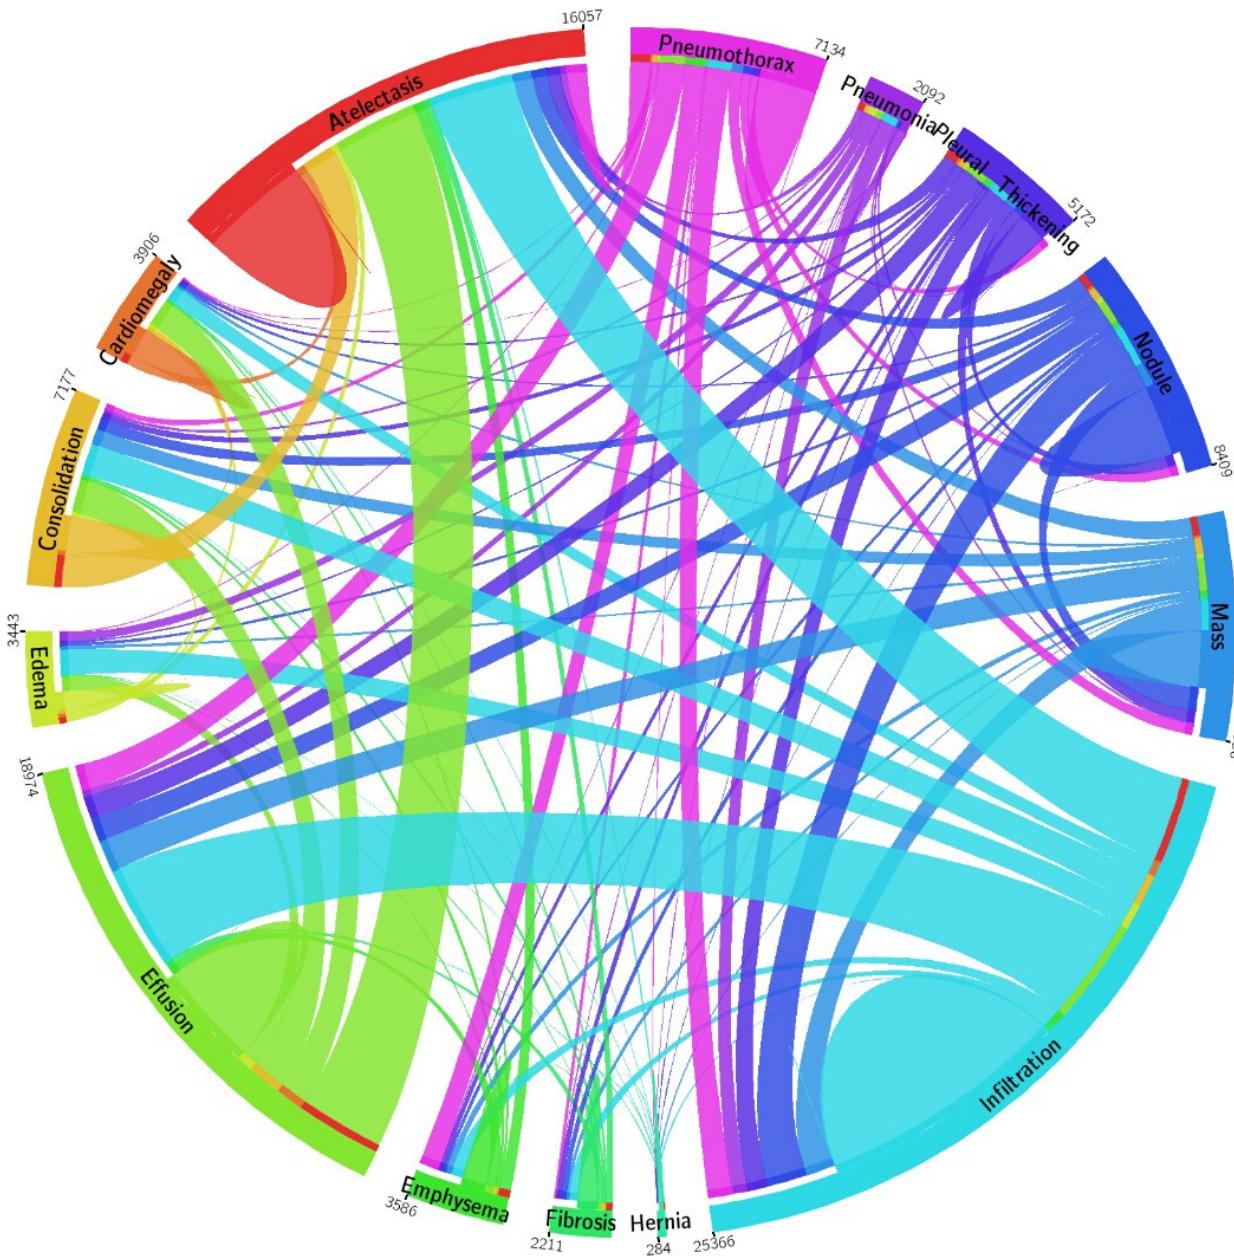
ENFISEMA

FIBROSIS

ENGROSAMIENTO PLEURAL

HERNIA





- Base de datos altamente desbalanceada
- Alta proporción de pacientes con más de una enfermedad (Multi-label task)

# ESTADO DEL ARTE

## PROPOSITO

- Clasificación de imágenes de etiquetas múltiples.
- Marco de localización de patología débilmente supervisados

## MODELO

Clasificación multi-label DCNN  
(Deep Convolutional Network) [1].

Pre-entrenado en ImageNet utilizando  
(Alexnet,Resnet50,GoogleNet)

## ChestX-ray8: Hospital-scale Chest X-ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases

Xiaosong Wang<sup>1</sup>, Yifan Peng<sup>2</sup>, Le Lu<sup>1</sup>, Zhiyong Lu<sup>2</sup>, Mohammad Bagheri<sup>1</sup>, Ronald M. Summers<sup>1</sup>

<sup>1</sup>Department of Radiology and Imaging Sciences, Clinical Center,

<sup>2</sup> National Center for Biotechnology Information, National Library of Medicine,  
National Institutes of Health, Bethesda, MD 20892

{xiaosong.wang,yifan.peng,le.lu,luzh,mohammad.bagheri,rms}@nih.gov

## ARQUITECTURA

Cambios en DenseNet. Capa de global pooling y una completamente conectada.

Diferentes funciones de error: Hinge Loss (HL), Euclidean loss (EL) and Cross Entropy Loss (CEL)

# ESTADO DEL ARTE

## CARACTERÍSTICAS

- Problema: Wang et al., asume labels independientes.
- Modelar la interdependencia en las enfermedades

## MODELO

- Basado en redes recurrentes (RNN) adaptando Long-short Term Memory Networks (LSTM) [2].
- Modelo no pre-entrenado

## LEARNING TO DIAGNOSE FROM SCRATCH BY EXPLOITING DEPENDENCIES AMONG LABELS

**Li Yao, Eric Poblenz, Dmitry Dagunts, Ben Covington, Devon Bernard, Kevin Lyman**  
Enlitic Inc.  
San Francisco, CA 94111, USA  
[{li,eric,dmitry,ben,devon,kevin}@enlitic.com](mailto:{li,eric,dmitry,ben,devon,kevin}@enlitic.com)

## ARQUITECTURA

- Función de error : MLE cross-entropy. Fue ajustada para tener el cuenta el desbalance entre clases.
- Función sigmoide
- Aumento de datos

# ESTADO DEL ARTE

## CARACTERÍSTICAS

- Modelo basado en una red convolucional densa.
- Resultados del estado del arte actuales.

• Modelos:

## MODELO

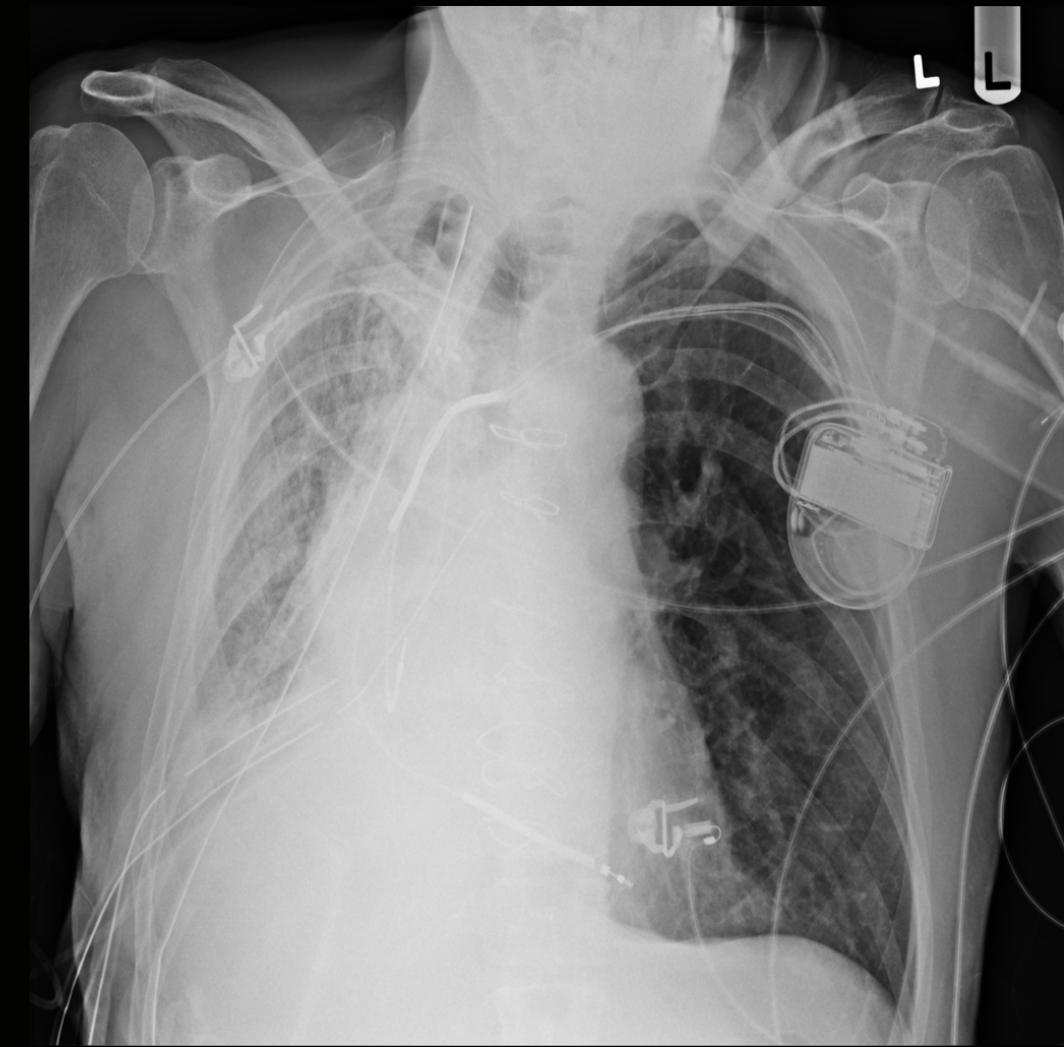
- DenseNet-121
- Pre-entrenado en ImageNet [3]

## CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning

Pranav Rajpurkar <sup>\*1</sup> Jeremy Irvin <sup>\*1</sup> Kaylie Zhu <sup>1</sup> Brandon Yang <sup>1</sup> Hershel Mehta <sup>1</sup>  
Tony Duan <sup>1</sup> Daisy Ding <sup>1</sup> Aarti Bagul <sup>1</sup> Robyn L. Ball <sup>2</sup> Curtis Langlotz <sup>3</sup> Katie Shpanskaya <sup>3</sup>  
Matthew P. Lungren <sup>3</sup> Andrew Y. Ng <sup>1</sup>

## ARQUITECTURA

- Función de error : BCE (Binary cross-entropy)
- Capa completamente conectada: output dimensión 14
- Optimizador Adam



---

# BASELINE

- ▶ Método de PHOW modificado
- ▶ 10000 imágenes de entrenamiento
- ▶ 5000 imágenes de test
- ▶ 14 SVM uno vs todos
- ▶ 31.37 % de auroc score en promedio

# EXPERIMENTOS

---



## VGG 11 BN

Modelo sin pre-entrenamiento.



## VGG 11 BN

Modelo pre-entrenado en  
ImageNet



## RESNET 50

Modelo pre-entrenado en  
ImageNet.



## RESNET 101

Modelo pre-entrenado en  
ImageNet

# AUMENTO DE DATOS

## RESIZE

Las imágenes fueron escaladas a 256x256

## FLIP HORIZONTAL

Flip horizontal realizado de forma aleatoria

## RANDOM SIZE CROP

Selección de partes aleatorias de la imagen de 224x224

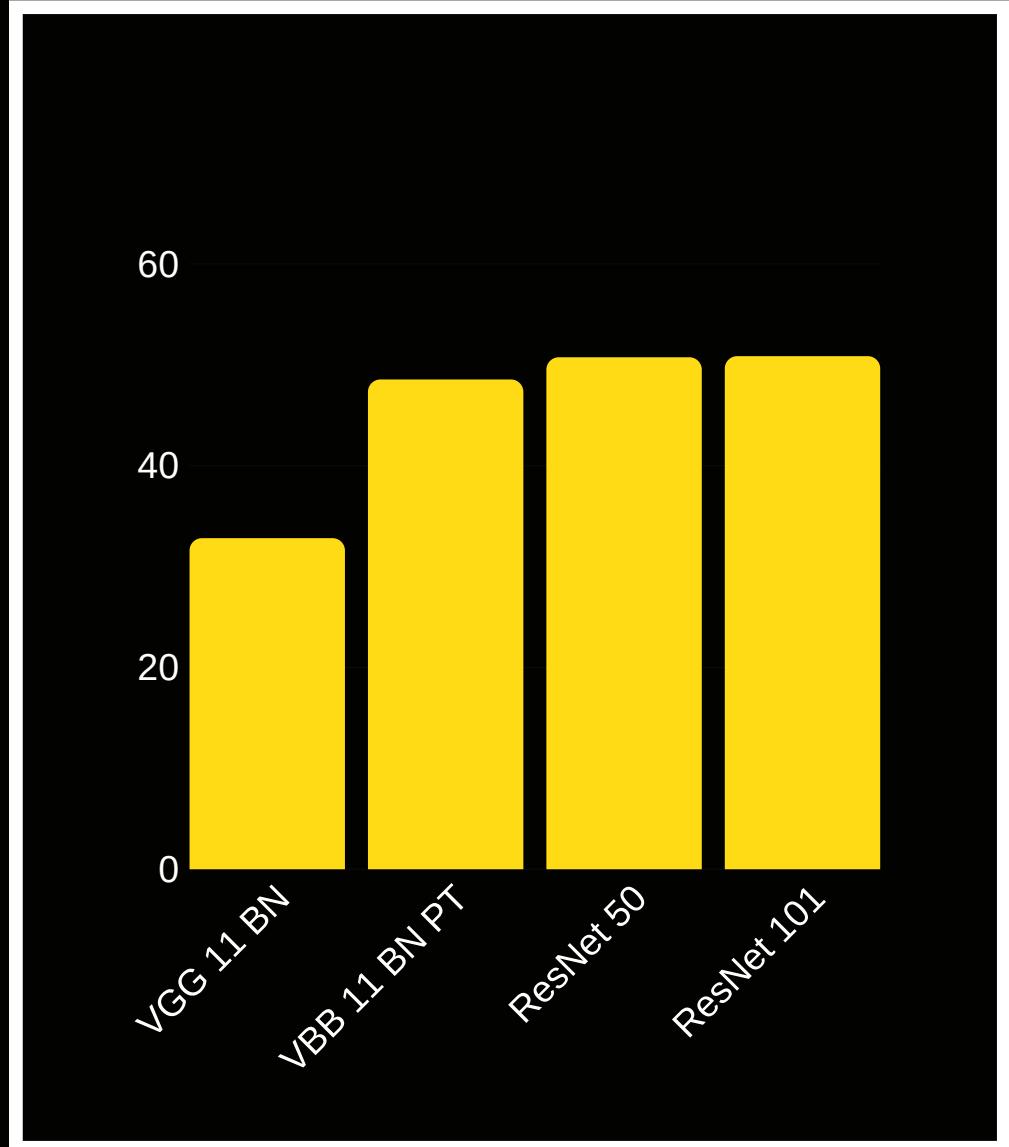
## NORMALIZACIÓN

Normalización de acuerdo a la media y desviación de ImageNet

# ALGORITMO FINAL

AUMENTO DE DATOS	RESNET 50	OBTENCIÓN DE PREDICIONES	EVALUACIÓN
Utilizado para el entrenamiento del modelo	Modelo pre-entrenado en ImageNet	Se aplica un sigmoide luego de obtener la respuesta del modelo	Curva Roc y Auroc score

# RESULTADOS FINALES



**32.75%**

—  
MODELO DE VGG 11 BN  
SIN PRE ENTRENAMIENTO

**48.48 %**

—  
MODELO DE VGG 11 BN  
PRE-ENTRENADO EN  
IMAGENET

# RESNET 101

7 horas 20 minutos de  
entrenamiento

50.79 % promedio de  
auroc score

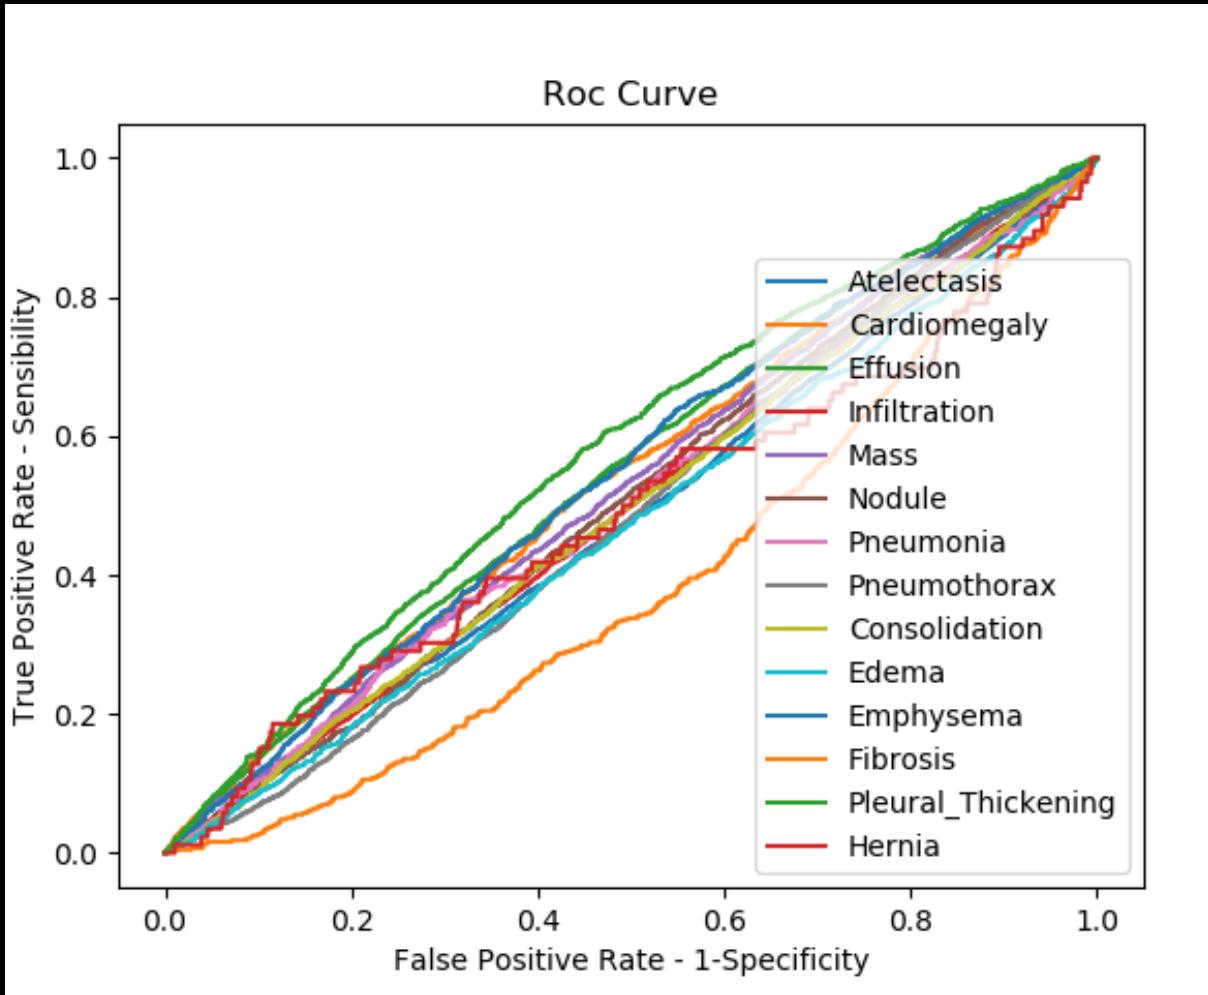
Mejor auroc score de  
57.6% - Edema

# RESNET 50

6 horas de  
entrenamiento

50.68 % promedio de  
auroc score

Mejor auroc score de  
57.9% - Engrosamiento  
pleural



# Curva ROC

- ▶ Fibrosis
- ▶ Engrosamiento pleural
- ▶ Distribución uniforme en la mayor parte de enfermedades

# COMPARACIÓN

Clase	Wang et al	Yao et al	Rajpurkar et al	Nosotros
Atelectasis	71,6%	77,2%	80,9%	49%
Cardiomegalia	80,7%	90,4%	92,5%	54,1%
Efusión	78,4%	85,9%	86,4%	55,1%
Infiltración	60,9%	69,5%	73,4%	50%
Masa	70,6%	79,2%	86,8%	52,8%
Nódulo	67,1%	71,7%	78%	51%
Pneumonia	63,3%	71,3%	76,8%	50,7%
Pneumotórax	80,6%	84,1%	88,9%	49%
Consolidación	70,8%	78,8%	79%	50%
Edema	83,5%	88,2%	88,8%	47,6%
Enfisema	81,5%	82,9%	93,7%	54,6%
Fibrosis	76,9%	76,7%	80,5%	39%
Engrosamiento pleural	70,8%	76,5%	80,6%	57,9%
Hernia	76,7%	91,4%	91,6%	48,8%
Promedio	73,81%	80,27%	86,57%	50,68%

# DISCUSIÓN

- ENFERMEDAD MÁS DIFÍCIL DE CLASIFICAR
- ENFERMEDAD MEJOR CLASIFICADA

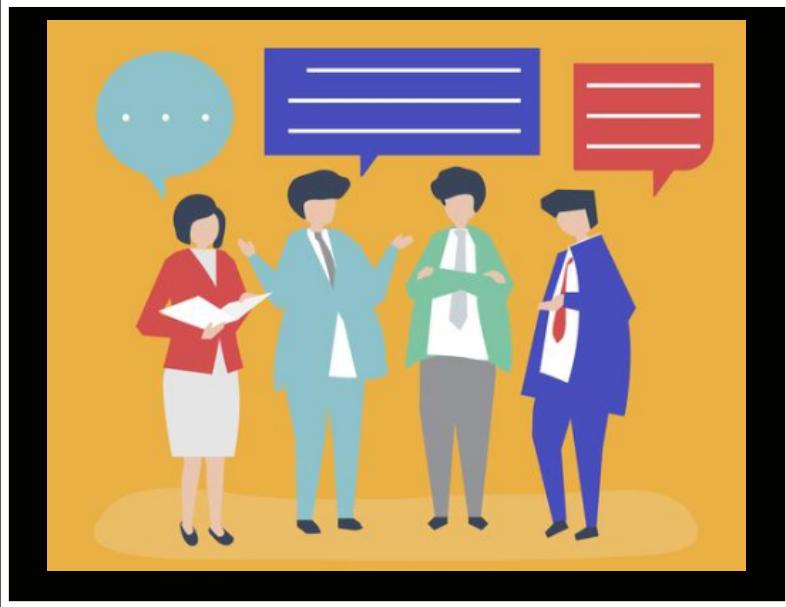
Fibrosis



Engrosamiento pleural



# DISCUSIÓN



## POSIBLES MODIFICACIONES

- Red recurrente por una densa (DenseNet): Resultados estado del arte.
- Mayor número de parámetros y capas (121,162)
- Entrenar la red propia con más épocas y comparar resultados.
- Mapa de calor: output con base a la capa previa a la completamente conectada
- Seleccionar secciones de interés. Ej: Pulmones. Arquitectura DNetLoc [4]

## DIFICULTADES

- Algoritmo entrenado con tan solo 10 épocas. Rajpurkar et al. (100 épocas)

# QUIÉNES SOMOS

SAÚL CAMILO GÓMEZ

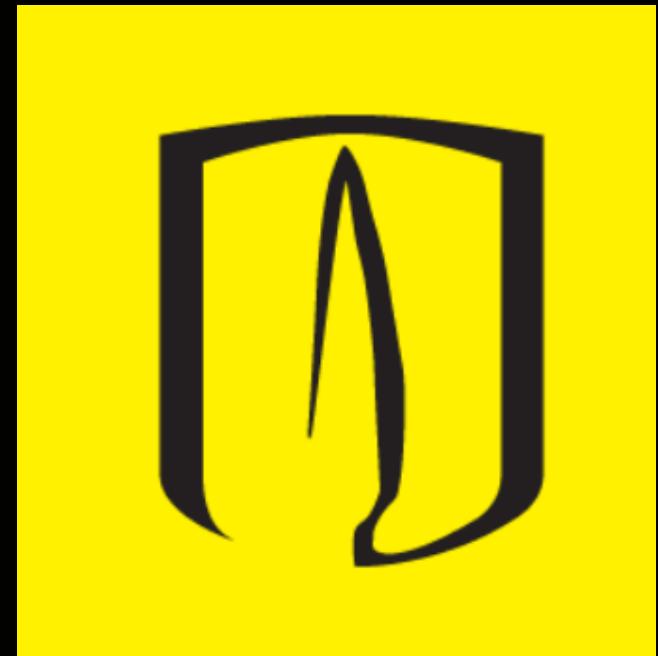
sc.gomez11@uniandes.edu.co

MATEO RUEDA

ms.rueda10@uniandes.edu.co

DIEGO VALDERRAMA

df.valderrama@uniandes.edu.co



# REFERENCIAS

- [1] X. WANG, Y. PENG, L. LU, Z. LU, M. BAGHERI, AND R. SUM- MERS. CHESTX-RAY8: HOSPITAL-SCALE CHEST X-RAY DATABASE AND BENCHMARKS ON WEAKLY-SUPERVISED CLASSIFICATION AND LOCALIZATION OF COMMON THORAX DISEASES. IN 2017 IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION(CVPR).
- [2] L. YAO, E. POBLENZ, D. DAGUNTS, B. COVINGTON, D. DEVON BERNARD, AND K. LYMAN. LEARNING TO DIAGNOSE FROM SCRATCH BY EXPLOIT- ING DEPENDENCIES AMONG LABELS. ARXIV:1710.10501.2017
- [3] P. RAJPURKAR, J. IRVIN, K. ZHU, B. YANG, H. MEHTA, T. DUAN, D. DING, A. BAGUL, R. BALL, C. LANGLOTZ, K. SHPANSKAYA, M. LUNGREN, AND Y. NG. CHEXNET: RADIOLOGIST-LEVE PNEUMONIA DETECTION ON CHEST X-RAYS WITH DEEP LEARNING. ARXIV:1711.05225V3.2017.
- [4] S. GUNDEL, S. GRBIC, B. GEORGESCU, S. K. ZHOU, L. RITSCHL, A. MEIER, AND D. COMANICIU. LEARNING TO RECOGNIZE ABNORMALITIES IN CHEST X-RAYS WITH LOCATION-AWARE DENSE NETWORKS.CORR,ABS/1803.04565, 2018